

Math-Net.Ru

Общероссийский математический портал

П. С. Козырь, А. И. Савельев, Анализ эффективности методов машинного обучения в задаче распознавания жестов на основе данных электромиографических сигналов, *Компьютерные исследования и моделирование*, 2021, том 13, выпуск 1, 175–194

DOI: 10.20537/2076-7633-2021-13-1-175-194

Использование Общероссийского математического портала Math-Net.Ru подразумевает, что вы прочитали и согласны с пользовательским соглашением

<http://www.mathnet.ru/rus/agreement>

Параметры загрузки:

IP: 88.201.239.181

22 декабря 2023 г., 15:49:29



УДК: 004.93'12

Анализ эффективности методов машинного обучения в задаче распознавания жестов на основе данных электромиографических сигналов

П. С. Козырь^a, А. И. Савельев^b

Санкт-Петербургский Федеральный исследовательский центр Российской академии наук,
Санкт-Петербургский институт информатики и автоматизации Российской академии наук,
Россия, 199178, г. Санкт-Петербург, 14 линия, д. 39

E-mail: ^a polinatrump@mail.ru, ^b saveliev.ais@yandex.ru

Получено 30.09.2020, после доработки — 09.02.2021.

Принято к публикации 09.02.2021.

При разработке систем человеко-машинных интерфейсов актуальной является задача распознавания жестов. Для выявления наиболее эффективного метода распознавания жестов был проведен анализ различных методов машинного обучения, используемых для классификации движений на основе электромиографических сигналов мышц. Были рассмотрены такие методы, как наивный байесовский классификатор (НБК), дерево решений, случайный лес, градиентный бустинг, метод опорных векторов, метод k -ближайших соседей, а также ансамбли методов (НБК и дерево решений, НБК и градиентный бустинг, градиентный бустинг и дерево решений). В качестве метода получения информации о жестах была выбрана электромиография. Такое решение не требует расположения руки в поле зрения камеры и может быть использовано для распознавания движений пальцев рук. Для проверки эффективности выбранных методов распознавания жестов было разработано устройство регистрации электромиографического сигнала мышц предплечья, которое включает в себя три электрода и ЭМГ-датчик, соединенный с микроконтроллером и блоком питания. В качестве жестов были выбраны: сжатие кулака, знак «большой палец», знак «Виктория», сжатие указательного пальца и взмах рукой справа налево. Оценка эффективности методов классификации проводилась на основе значений доли правильных ответов, точности, полноты, а также среднего значения времени работы классификатора. Данные параметры были рассчитаны для трех вариантов расположения электромиографических электродов на предплечье. По результатам тестирования, наиболее эффективными методами являются метод k -ближайших соседей, случайный лес и ансамбль НБК и градиентного бустинга, средняя точность которого для трех положений электродов составила 81,55 %. Также было определено положение электродов, при котором методы машинного обучения достигают максимального значения точности распознавания. При таком положении один из дифференциальных электродов располагается на месте пересечения глубокого сгибателя пальцев и длинного сгибателя большого пальца, второй — над поверхностным сгибателем пальцев.

Ключевые слова: машинное обучение, распознавание жестов, человеко-машинный интерфейс, электромиография, ансамбль методов, градиентный бустинг, метод k -ближайших соседей, дерево решений

UDC: 004.93'12

Analysis of the effectiveness of machine learning methods in the problem of gesture recognition based on the data of electromyographic signals

P. S. Kozyr^a, A. I. Saveliev^b

St. Petersburg Federal Research Center of the Russian Academy of Sciences (SPC RAS),
St. Petersburg Institute for Informatics and Automation of the Russian Academy of Sciences,
39, 14th Line, Saint-Petersburg, 199178, Russia

E-mail: ^a polinatrump@mail.ru, ^b saveliev.ais@yandex.ru

Received 30.09.2020, after completion — 09.02.2021.

Accepted for publication 09.02.2021.

Gesture recognition is an urgent challenge in developing systems of human-machine interfaces. We analyzed machine learning methods for gesture classification based on electromyographic muscle signals to identify the most effective one. Methods such as the naive Bayesian classifier (NBC), logistic regression, decision tree, random forest, gradient boosting, support vector machine (SVM), k-nearest neighbor algorithm, and ensembles (NBC and decision tree, NBC and gradient boosting, gradient boosting and decision tree) were considered. Electromyography (EMG) was chosen as a method of obtaining information about gestures. This solution does not require the location of the hand in the field of view of the camera and can be used to recognize finger movements. To test the effectiveness of the selected methods of gesture recognition, a device was developed for recording the EMG signal, which includes three electrodes and an EMG sensor connected to the microcontroller and the power supply. The following gestures were chosen: clenched fist, “thumb up”, “Victory”, squeezing an index finger and waving a hand from right to left. Accuracy, precision, recall and execution time were used to evaluate the effectiveness of classifiers. These parameters were calculated for three options for the location of EMG electrodes on the forearm. According to the test results, the most effective methods are k-nearest neighbors’ algorithm, random forest and the ensemble of NBC and gradient boosting, the average accuracy of ensemble for three electrode positions was 81.55%. The position of the electrodes was also determined at which machine learning methods achieve the maximum accuracy. In this position, one of the differential electrodes is located at the intersection of the flexor digitorum profundus and flexor pollicis longus, the second — above the flexor digitorum superficialis.

Keywords: machine learning, gesture recognition, human-machine interface, electromyography, ensemble learning, gradient boosting, *k*-nearest neighbors’ algorithm, decision tree.

Citation: *Computer Research and Modeling*, 2021, vol. 13, no. 1, pp. 175–194 (Russian).

© 2021 Polina S. Kozyr, Anton I. Saveliev

This work is licensed under the Creative Commons Attribution-NoDerivs 3.0 Unported License.

To view a copy of this license, visit <http://creativecommons.org/licenses/by-nd/3.0/>
or send a letter to Creative Commons, PO Box 1866, Mountain View, CA 94042, USA.

1. Введение

Системы распознавания жестов широко используются для реализации дистанционного управления робототехническими устройствами, а также в медицине для восстановления утраченных двигательных функций и протезирования конечностей пациентов. Для решения задачи распознавания жестов применяются электромиография, методы обработки изображений [Nagashree et al., 2005; Mehra, 2018; Nguyen et al., 2014; Lee et al., 2020; Cho et al., 2018], анализ пространственной ориентации объекта, полученной при помощи инерциальных датчиков [Teachasrisaksakul et al., 2018], эпидермальные тактильные датчики [Byun, Lee, 2019] и т. д. Для систем распознавания жестов на основе методов обработки изображений обязательным условием является расположение руки непосредственно в пределах обзора камеры (нескольких камер), что затрудняет их использование в заранее неподготовленной среде и усложняет аппаратную базу. Системы распознавания жестов, основанные на инерциальных датчиках, имеют высокую точность классификации, однако не могут быть использованы для распознавания движений пальцев [Teachasrisaksakul et al., 2018]. Использование эпидермальных тактильных датчиков, расположенных на запястьях, также не является эффективным, так как такой подход имеет низкую точность распознавания движений пальцев рук.

В настоящее время одним из наиболее перспективных методов получения информации о жестах является электромиография. Электромиография (ЭМГ) представляет собой метод регистрации и оценки электрической активности скелетных мышц человека. При движении рук происходит возбуждение мышечных волокон, что сопровождается возникновением биоэлектрических потенциалов, для регистрации которых используют ЭМГ-электроды. Полученные сигналы являются входными данными для методов классификации жестов. Преимуществами систем распознавания жестов на основе ЭМГ являются малые массогабаритные параметры и возможность реализации таких систем в виде портативных устройств.

Точность классификации жестов относительно эталонных значений, соответствующих базовым жестам, зависит от использованных методов распознавания. Одним из простейших методов классификации является метод k -ближайших соседей [Mirjalili et al., 2018]. Данный метод основан на определении объекта в класс, которому принадлежит большинство из его k -ближайших соседей в многомерном пространстве признаков. Для нахождения ближайших точек (соседей) происходит расчет расстояния между точками. Главным недостатком метода k -ближайших соседей является высокая временная сложность. Данный метод был использован при реализации устройства для восстановления двигательных функций людей после инсульта [Lyu et al., 2017]. Набор признаков включал в себя среднее значение ЭМГ-сигнала, стандартное отклонение и длину волны и был рассчитан при помощи движущегося окна. Точность распознавания состояния покоя, разгибания запястья и неправильного выполнения жеста составила 92.5 ± 6.9 %.

Метод k -ближайших соседей также может быть использован совместно с линейным дискриминантным анализом (ЛДА) [Geng et al., 2014]. ЛДА представляет собой метод поиска линейной комбинации признаков, которая характеризует или разделяет объекты или события на два (или более) класса [Zhang et al., 2019]. Средняя точность классификации жестов составляла 93.03 % при использовании восемнадцати оптимальных монополярных ЭМГ-каналов, а при использовании всех пятидесяти шести монополярных ЭМГ каналов — 94.50 % [Geng et al., 2014].

Задача распознавания жестов может быть также решена с помощью бинарной классификации или сведена к ней. Для моделирования зависимости выходной бинарной переменной от набора входных признаков используется логистическая регрессия [Molnar, 2020]. Логистическая регрессия является одним из методов обучения с учителем. Классификация объектов осуществляется при помощи логистической функции, значением которой является вероятность принадлежности объекта к классу. В работе [Purushothaman, Ray, 2014] максимальная точность классификации методом логистической регрессии шести жестов среди десяти участников эксперимента составила 91.2 %.

К статистическим методам машинного обучения относится наивный байесовский классификатор (НБК). НБК основан на теореме Байеса со строгими предположениями о независимости. НБК характеризуется низкой степенью сложности и малым временем работы, а также может использоваться с данными большого объема. Тем не менее в реальности признаки зачастую зависимы, то есть наивное предположение о независимости не всегда выполняется [Bolsstad, Curran, 2016]. При распознавании 27 жестов с использованием 192 электродов средняя точность классификации НБК составила 90.2 % [Hu et al., 2018].

Наивный подход также используется при построении деревьев решений [Smith, Koning, 2017]. Дерево решений представляет собой древовидный граф, состоящий из узлов и ребер («веток»), на которых записаны признаки. При построении деревьев классификации предсказывается принадлежность объекта к той или иной категории целевой переменной в зависимости от соответствующих значений признаков. Данный метод характеризуется невысокой точностью классификации и нестабильностью предсказаний. Так, при распознавании десяти жестов точность данного метода составила 69 % при использовании трех ЭМГ-датчиков [Lian et al., 2017].

Множество деревьев решений образует метод «случайный лес». При решении задачи классификации данный статистический метод создает деревья решений из случайных выборок данных, получает прогнозы по каждому дереву и выбирает лучшее решение с помощью голосования [Smith, Koning, 2017]. Главным недостатком метода является высокая временная сложность. Средняя точность классификации пятнадцати жестов случайным лесом составила 91.47 % при использовании восьми ЭМГ-датчиков [Zhang et al., 2017].

Ансамбль последовательно уточняющих друг друга деревьев решений называется градиентным бустингом деревьев решений (gradient boosting decision tree). Наиболее популярной реализацией данного метода является библиотека машинного обучения XGBoost (EXtreme Gradient Boosting). Использование XGBoost позволило достичь точности распознавания двенадцати жестов 91 % [Song et al., 2019]. Применение ансамблей методов позволяет повысить точность распознавания по сравнению со случаем, когда методы используются по отдельности [Demir].

Еще одним статистическим методом машинного обучения является скрытая марковская модель. Зачастую скрытые марковские модели используются для работы с временными данными. Сложность применения данного метода заключается в необходимости построения правильной архитектуры модели, соответствующей конкретной задаче [Mor et al., 2020]. При использовании двенадцати ЭМГ-датчиков точность распознавания восемнадцати жестов с использованием скрытых марковских моделей составила от 76 до 98 % [Samadani, 2018].

Также для распознавания жестов может быть использован метод нейросетей, например многослойный перцептрон и сверточная нейронная сеть. Многослойный перцептрон обладает высокой степенью связности между синаптическими соединениями. Сильная нелинейность и связность сети существенно осложняют анализ работы многослойного перцептрона. При распознавании шести жестов многослойный перцептрон показал максимальную точность распознавания — 98.8 % [Zhang et al., 2019; Sahin, Sahin, 2012].

Сверточные нейронные сети (СНС) являются регуляризованными версиями многослойных перцептронов. Несмотря на высокую точность распознавания, порядка 98 % (для восьми жестов) [Tam et al., 2019], СНС требует больше время для обучения по сравнению со статистическими методами. Кроме того, необходима эмпирическая настройка параметров сети, что затрудняет реализацию СНС.

Точность распознавания рассмотренных выше методов (k -ближайших соседей, СНС и НБК) зависит от размера обучающей выборки, при этом для осуществления классификации необходимы все экземпляры выборки. Метод опорных векторов (МОВ) может применяться в случаях, когда, кроме опорных векторов, другие экземпляры выборки отсутствуют. МОВ заключается в создании гиперплоскости в многомерном пространстве для разделения его на разные классы. Необходимо найти максимальную предельную гиперплоскость, которая наилучшим образом подразделяет набор данных на классы. Данный метод обеспечивает высокую точность классификации для пространств высокой размерности (со множеством признаков). Тем не менее для обучения МОВ большому набору данных требуется достаточно продолжительное время, боль-

шее по сравнению с НБК [Navlani, 2019]. При использовании МОБ для распознавания трех жестов в системах реабилитации больных в домашних условиях точность данного метода составила 94.3 % для здоровых людей и 78.8 % для лиц, переживших инсульт [Ryser et al., 2017], при этом для получения ЭМГ-сигналов использовались восемь датчиков.

Данная работа направлена на определение наиболее эффективного метода распознавания жестов. Для этого был проведен анализ эффективности различных методов машинного обучения для решения задачи распознавания жестов с использованием ЭМГ-сигнала. В качестве методов машинного обучения были рассмотрены наиболее часто используемые методы: НБК, дерево решений, случайный лес, МОБ, метод k -ближайших соседей, градиентный бустинг и ансамбли (НБК и дерева решений, НБК и градиентного бустинга, градиентного бустинга и дерева решений). Подробнее о данных методах см. в источниках [Mirjalili, 2019; Bolstad, Curran, 2016; Smith, Koning, 2017; Demir; Navlani, 2019].

2. Устройство регистрации электромиографического сигнала мышц

Для проверки эффективности выбранных методов распознавания жестов было разработано устройство регистрации электромиографического сигнала мышц предплечья. Данное устройство представляет собой три электрода и ЭМГ-датчик, соединенный с микроконтроллером и блоком питания. Сигнал, снимаемый электродами с поверхности тела человека, поступает на ЭМГ-датчик, усиливается, фильтруется и поступает на микроконтроллер ESP32. ESP32 осуществляет АЦП 12-битное преобразование и передает сигнал в цифровом виде на персональный компьютер по сети Wi-Fi. ЭМГ-датчик включает в себя инструментальный усилитель INA128 (Texas Instruments), керамический конденсатор 47 мкФ и переключающий диод TS4148 RY. На рис. 1 представлена принципиальная схема данного датчика.

Для снятия сигнала с биообъекта используются три электрода: положительный, отрицательный и референтный (заземленный). Для регистрации ЭМГ-сигнала мышц предплечья заземляющий электрод должен располагаться над костной областью с минимальной биоэлектрической активностью мышц. Точное место крепления электродов определялось перемещением электродов и поиском зоны с наиболее высоким откликом ЭМГ-сигнала. В качестве электродов использовались одноразовые ЭКГ/ЭМГ-электроды Ag/AgCl диаметром 8 мм.




Рис. 1. Принципиальная схема ЭМГ-датчика: V_{in-} , V_{in+} — входы дифференциальных электродов, Ref — вход референтного электрода, V_0 — выход усилителя

Микросхема INA128 представляет собой маломощный инструментальный усилитель, применяемый в настоящем устройстве для усиления сигнала, полученного с дифференциальных входов от ЭМГ-датчика. Выводами 1 и 8 калибруют коэффициент усиления сигнала G путем подключения между ними усиливающего резистора для получения коэффициента усиления больше 1 по постоянному току. В данном ЭМГ-датчике для этого используется реактивный импеданс конденсатора, который обеспечивает усиление, зависящее от частоты, тем самым усиливая более высокие частоты. Так как реактивное сопротивление ёмкости зависит от частоты, то и коэффициент усиления зависит от частоты. Коэффициент усиления по переменному току находился в диапазоне от 700 до 2000. Амплитудно-частотная характеристика (АЧХ) усилителя представлена на рис. 2. Полное сопротивление конденсатора, которое является обратно пропорциональным усилению электромиографического сигнала, рассчитывается следующим образом:

$$X_G = \frac{1}{2\pi fC},$$

где f — частота сигнала, C — емкость конденсатора. Сигнал на выходе усилителя:

$$V_0 = G(V_{in+} - V_{in-}),$$

где V_{in+} и V_{in-} — напряжения на дифференциальных входах, G — коэффициент усиления:

$$G = 1 + \frac{2R_1}{X_G}.$$

Во время обработки сигнала микросхемой происходит вычитание синфазного сигнала, полученного с заземляющего электрода (Ref) из сигналов дифференциальных входов (принимает два сигнала и вычитает общий в обоих), что приводит к частичному подавлению фонового шума, имеющегося на обоих каналах. Для подавления отрицательной части сигнала в данной схеме был установлен диод.




Рис. 2. АЧХ усилителя INA128

3. Процесс распознавания жестов

Распознавание жестов основывается на обработке признаков, характеризующих их. Однако данные, полученные ЭМГ-датчиком, искажены фоновыми помехами, поэтому необходимо предварительно использовать фильтры. Далее из отфильтрованного сигнала выделяются признаки. Затем полученные признаки подаются на классификатор, который соотносит движение руки с жестом. На рис. 3 представлен процесс распознавания жестов с момента их регистрации и до выдачи результата классификатором.

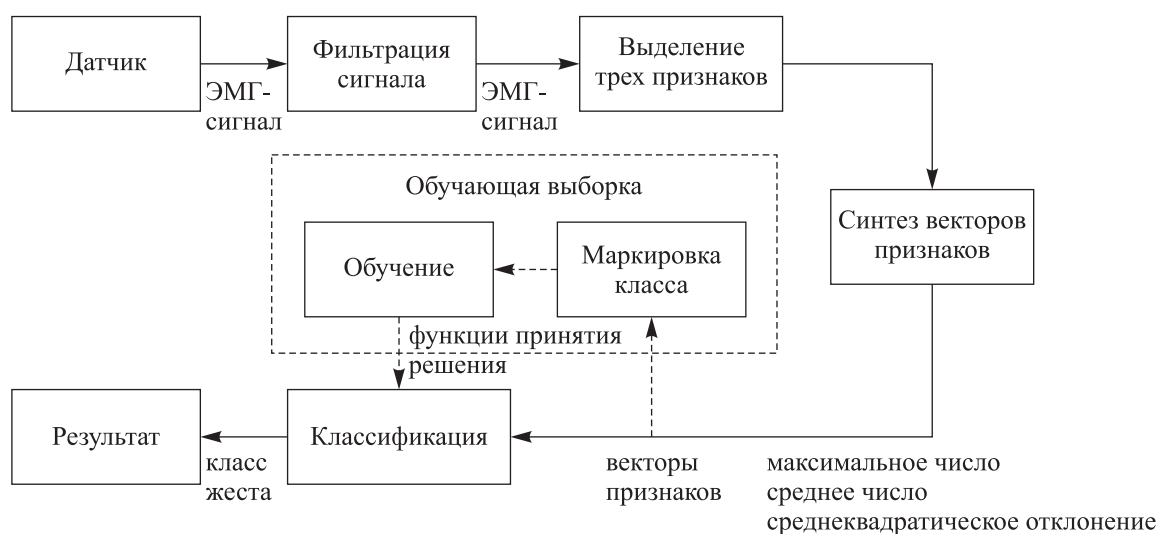


Рис. 3. Схема обработки сигнала ЭМГ-датчика в задаче распознавания жестов методами машинного обучения

Для устранения шумов и выделения значащих гармоник необходимо изменять амплитудные спектры сигналов. Исходя из этого выполнялось дискретное преобразование Фурье исходного сигнала. Поскольку сигналы ЭМГ имеют низкую амплитуду в диапазоне от микровольт до милливольт и частотный диапазон 5–450 Гц, был использован фильтр, отсеивающий высокие частоты.

Для уменьшения эффекта Гиббса и улучшения характеристик фильтра используют метод частотной выборки с применением оконного сглаживания. Результатом оконного преобразования Фурье является спектр произведения сигнала и оконной функции. Для борьбы с растеканием спектра применяют более гладкую оконную функцию, спектр которой имеет более широкий главный лепесток и низкий уровень боковых лепестков. В качестве такой функции выбрано окно Хэмминга, так как оно обладает достаточно высокой эффективностью по сравнению с другими окнами. Модель системы фильтрации описывалась следующим выражением:

$$f \cdot g = IFFT(FFT(f) \cdot FFT(g)),$$

где $f \cdot g$ — это искомый фильтрованный сигнал, FFT — быстрое преобразование Фурье (БПФ), $IFFT$ — обратное (БПФ). На рис. 4 представлен пример графика исходного и обработанного сигналов. Амплитуда сигналов представлена в выходных значениях АЦП.

После фильтрации модуль выделения признаков осуществляет вычленение из ЭМГ-сигнала фрагмента, соответствующего наличию жеста. Сначала необходимо определить, показывает или нет испытуемый какой-либо жест в заданный момент времени. В данной работе определение наличия жеста основано на сравнении значений амплитуды сигнала, прошедшего фильтрацию, с пороговым значением. Амплитуда ЭМГ сигнала покоящейся на столе руки в расслабленном состоянии имеет относительно ровный характер, без выдающихся скачков напряжения (которые характерны для движений рукой). В момент совершения жеста мотонейроны и мышечные волокна возбуждаются и сокращаются, что сопровождается возникновением потенциала действия. Превышение порога напряжения, характерного для расслабленного состояния руки, означает, что рука совершает некоторое активное движение, в настоящем эксперименте — единственный жест. В данном случае, когда амплитуда сигнала преодолевает заданный уровень и удерживается выше него некоторое время, ее значения, превышающие порог, записываются в новый массив до тех пор, пока движение не завершится, рука не окажется в расслабленном состоянии и значения амплитуды фильтрованного сигнала снова не будут ниже порога. В результате каждый такой массив содержит информацию об амплитуде сигнала единичного жеста.




Рис. 4. Пример исходного и обработанного сигналов: а) выходной сигнал ЭМГ-датчика; б) сигнал ЭМГ-датчика, прошедший фильтрацию

На следующем этапе необходимо получить векторы признаков жестов, на основе которых классификатор будет делать прогноз. Извлечение признаков из данных ЭМГ-сигнала можно осуществлять во временной, в частотной и в частотно-временной областях. В большинстве случаев обработка признаков, относящихся ко временной области, наиболее проста, эффективна и требует меньше вычислений, поэтому такие признаки подходят в качестве данных для анализа при реализации алгоритмов распознавания жестов на микроконтроллерах [Ke et al., 2020; Samadani, 2018]. В настоящем исследовании для каждого массива данных, содержащего значения амплитуды ЭМГ-сигнала в момент совершения жеста, выделяются следующие признаки:

- 1) максимальное значение амплитуды сигнала жеста;
- 2) среднее абсолютное значение амплитуды сигнала жеста $\overline{\text{ЭМГ}}$:

$$\overline{\text{ЭМГ}} = \frac{1}{n} \sum_{i=0}^{n-1} |\text{ЭМГ}_i|,$$

где n — количество элементов в массиве жеста, ЭМГ — значение элемента массива, i — номер элемента массива;

- 3) среднеквадратическое отклонение значений массива std :

$$std = \sqrt{\frac{1}{n} \sum_{i=1}^n (\text{ЭМГ}_i - \overline{\text{ЭМГ}})^2}.$$

Рассчитанные признаки для каждого жеста записываются в виде векторов признаков:

$$F_j = \{std_j, \max_j, mean_j\},$$

где j — номер жеста, \max — максимальное значение амплитуды ЭМГ-сигнала жеста, $mean$ — среднее абсолютное значение амплитуды ЭМГ-сигнала жеста.

В зависимости от размерности векторов признаков результаты методов машинного обучения также могут изменяться. Количество признаков зависит от полезной информации, которую они могут дать о жесте, от специфики используемого метода машинного обучения, а также от времени, отведенного разработчиками системы, на обработку данных методами машинного обучения.

Создание обучающей выборки и обработка ее классификатором осуществляются модулями «маркировка класса» и «обучение». В качестве обучающей выборки для классификатора используется два массива: массив векторов признаков и массив с числовым значением для каждого типа жеста от 0 до 4. Примеры входных данных для методов машинного обучения представлены в табл. 1. Значения признаков представлены в выходных значениях АЦП.

Таблица 1. Пример обучающей выборки для методов машинного обучения

Признаки жеста			Номер жеста
max	mean	std	Label
154	135.13	22.45	0 (сжатие кулака)
150	118.55	26.95	0
101	79.09	17.45	1 (сжатие указательного пальца)
107	83.00	19.29	1
129	96.44	27.49	2 («Виктория»)

На рис. 5 представлено распределение признаков в трехмерном пространстве с использованием алгоритма t-SNE, где на цветовой палитре тип жеста обозначен соответствующим ему числовым значением (0 — сжатие кулака, 1 — сжатие указательного пальца, 2 — «Виктория», 3 — «большой палец», 4 — «взмах»). Значения, отложенные на осях графика, соответствуют значениям данных на выходе алгоритма t-SNE.




Рис. 5. Распределение признаков пяти жестов в трехмерном пространстве, полученное с использованием алгоритма t-SNE. На цветовой палитре для каждого жеста указано соответствующее ему числовое значение (0 — сжатие кулака, 1 — сжатие указательного пальца, 2 — «Виктория», 3 — «большой палец», 4 — «взмах»)

Реализация модуля классификации будет отличаться для разных методов машинного обучения своей структурой и математической и программной частью. Программная часть обработки сигнала осуществлялась с помощью языка программирования Python 3.8 с использованием библиотек NumPy (высокоуровневые математические функции и многомерные массивы), pandas (структуры данных), Scikit-learn (алгоритмы классификации, регрессии и кластеризации), xgboost (метод градиентного бустинга). В табл. 2–10 представлена основная информация о функциях, посредством которых были реализованы методы машинного обучения, и их параметрах.

Таблица 2. Параметры метода опорных векторов

Метод опорных векторов		
sklearn.svm.SVC()		
C	kernel	gamma
1.0	rbf	0.33

Здесь C — параметр регуляризации, величина регуляризации обратно пропорциональна C; параметр kernel задает тип ядра, который будет использоваться в алгоритме. Например, kernel = «linear» для линейной классификации или kernel = «rbf» для нелинейной классификации; gamma — коэффициент ядра для kernel = «rbf», kernel = «poly» и kernel = «sigmoid».

Таблица 3. Параметры метода дерева решений

Дерево решений			
sklearn.tree.DecisionTreeClassifier()			
criterion	splitter	max_depth	min_samples_split
gini	best	None	2

Для метода дерева решений используются следующие параметры: criterion — функция для измерения качества разделения в наборе данных; splitter — стратегия, используемая для выбора разделения в каждом узле; max_depth — максимальная глубина дерева; min_samples_split — минимальное количество выборок, необходимое для разделения внутреннего узла.

Таблица 4. Параметры наивного байесовского классификатора

Наивный байесовский классификатор	
sklearn.naive_bayes.GaussianNB()	
priors	var_smoothing
None	1e ⁻⁹

Параметры наивного байесовского классификатора: priors — априорные вероятности классов; var_smoothing — доля наибольшей дисперсии всех функций, которая добавляется к дисперсии для стабильности расчетов.

Таблица 5. Параметры метода «случайный лес»

Случайный лес			
sklearn.ensemble.RandomForestClassifier()			
n_estimators	criterion	max_depth	min_samples_split
100	gini	None	2

Параметры метода «случайный лес»: n_estimators — количество деревьев в лесу; criterion — функция для измерения качества разделения в наборе данных; max_depth — максимальная глубина дерева; min_samples_split — минимальное количество выборок, необходимое для разделения внутреннего узла.

Таблица 6. Параметры метода k -ближайших соседей

Метод k -ближайших соседей					
sklearn.neighbors.KNeighborsClassifier()					
n_neighbors	weights	algorithm	leaf_size	metric	p
3	uniform	auto	30	minkowski	2

Параметры метода k -ближайших соседей: `n_neighbors` — количество соседей для использования по умолчанию для запросов k соседей; `weights` — весовая функция, используемая в прогнозировании; `algorithm` — алгоритм, используемый для вычисления ближайших соседей; `auto` будет пытаться выбрать наиболее подходящий алгоритм на основе значений обучающей выборки, переданных методу `fit()`; `leaf_size` — размер листа, передается в алгоритмы `BallTree` или `KDTree` при их использовании. Этот параметр влияет на скорость построения, а также на объем памяти, необходимый для хранения дерева; `metric` — метрика, используемая для дерева; `p` — параметр мощности для метрики Минковского (эквивалентность использованию `euclidean_distance` при $p = 2$).

Таблица 7. Параметры метода градиентного бустинга

Градиентный бустинг					
xgboost.XGBClassifier()					
objective	max_depth	subsample	tree_method	booster	base_score
multi:softprob	6	1	exact	gbtree	0.5

Параметры метода градиентного бустинга: `objective` — указатель задачи обучения и соответствующей цели обучения; `multi:softprob` используется в случае мультиклассового разделения; `max_depth` — максимальная глубина дерева; `subsample` — соотношение подвыборок обучающей выборки; `tree_method` — используемый метод дерева; `booster` — используемый алгоритм предиктора; `base_score` — априорная вероятность прогноза для всех случаев.

Параметры, указанные ранее для соответствующих методов, объединенных в ансамбли, сохраняются. Всем ансамблям в разных положениях соответствуют параметры из табл. 9–11.

Таблица 8. Параметры ансамблей методов для положения 1

Ансамбли	voting	weights
Ансамбль (НБК, дерево решений)	hard	[1,1]
Ансамбль (НБК, градиентный бустинг)		
Ансамбль (градиентный бустинг, дерево решений)		
sklearn.ensemble.VotingClassifier()		

Таблица 9. Параметры ансамблей методов для положения 2

Ансамбли	voting	weights
Ансамбль (НБК, дерево решений)	hard	[2,1] (дерево решений, НБК)
Ансамбль (НБК, градиентный бустинг)	hard	[2,1] (градиентный бустинг, НБК)
Ансамбль (градиентный бустинг, дерево решений)	hard	[1,1]

Таблица 10. Параметры ансамблей методов для положения 3

Ансамбли	voting	weights
Ансамбль (градиентный бустинг, дерево решений)	hard	[1,1]
Ансамбль (НБК, дерево решений)		
Ансамбль (НБК, градиентный бустинг)	hard	[1,2] (градиентный бустинг, НБК)

4. Анализ эффективности методов распознавания жестов на основе машинного обучения

В качестве способа машинного обучения было выбрано обучение с учителем (supervised learning). Были рассмотрены следующие жесты: сжатие кулака, знак «большой палец», знак «Виктория», сжатие указательного пальца и взмах рукой справа налево (рис. 6). В исследовании принимало участие десять испытуемых, каждый из которых совершал по 100 жестов для каждого типа жестов (всего пять типов жестов) для одного из трех положений электродов. В общей сумме было отснято по 5000 жестов для каждого из трех экспериментов. Для каждого положения электродов обучающая выборка содержала 2500 жестов (по 500 сокращений мышц предплечья для каждого жеста). Тестовая выборка также состояла из 2500 жестов (по 500 сокращений мышц предплечья для каждого жеста). Все жесты выполнялись преобладающей правой рукой.




Рис. 6. Рассматриваемые в данной работе жесты: «большой палец», сжатие кулака, «взмах» (движение справа налево), «Виктория», сжатие указательного пальца

Для оценки эффективности распознавания жестов использовались доля правильных ответов, сходимость, количество ошибок и время работы классификатора. Доля правильных ответов классификации отражает процентное соотношение количества верных распознаваний жестов к общему числу проведенных классификаций и определяется по формуле

$$accuracy(y, \hat{y}) = \frac{1}{n} \sum_{i=0}^{n-1} 1(\hat{y}_i = y_i),$$

где \hat{y}_i — значение, полученное на классификации и соответствующее i -му жесту, y_i — значение, соответствующее истинному жесту, совершенному пользователем, n — общее число совершенных жестов, $1(x)$ — индикаторная функция.

Точность представляет собой отношение количества правильно распознанных жестов одного класса к количеству всех классификаций, ответами которых были жесты этого класса, и может быть рассчитана по формуле

$$precision = \frac{T_p}{T_p + F_p},$$

где T_p — количество объектов целевого класса, корректно отнесенных к целевому классу, F_p — ошибка первого рода (количество объектов выборки, ошибочно отнесенных к целевому классу (false positive)).

Полнота отражает долю правильно распознанных жестов одного класса из всех объектов, отнесенных классификатором к данному классу, и определяется по формуле

$$recall = \frac{T_p}{T_p + F_N},$$

где F_N — ошибка второго рода (количество объектов целевого класса, ошибочно отнесенных к другому классу (false negative)).

Расчет времени работы классификаторов производился на языке Python 3.8 с помощью средств модуля `datetime` (обработка времени). Время, затрачиваемое на обучение классификатора, не учитывалось, так как при реализации прототипов готовой системы предполагается, что классификатор уже обучен и только осуществляет прогнозы новых данных. Время распознавания каждого записанного жеста измерялось с момента подачи данных жеста в метод машинного обучения до получения прогноза классификатором.

Данные параметры были рассчитаны для трех положений дифференциальных электродов (рис. 7). Референтный электрод во всех трех случаях находится у локтя вне мышечной области.




Рис. 7. Исследуемые положения дифференциальных электродов: а) положение 1; б) положение 2; в) положение 3

5. Тестирование

На рис. 8 представлены графики амплитуды сигналов, полученных электродами ЭМГ-датчика в трех положениях, для каждого из исследуемых жестов. Каждый из совершаемых жестов имеет индивидуальное графическое изображение. Для успешного распознавания жестов необходимо, чтобы классификатор был способен детектировать разницу между данными кривыми амплитуды. Также полученные значения амплитуды ЭМГ-сигнала помогут определить такое положение электродов, при котором различие кривых максимально и, как следствие, выше точность классификации. В табл. 11 представлены результаты работы классификаторов для ЭМГ-сигналов, получаемых при помощи электродов в трех исследуемых положениях.

Таблица 11. Результаты работы классификаторов

Классификатор	Доля правильных ответов, %			Точность, %			Полнота, %			Среднее время работы, мс
	Положение электродов			Положение электродов			Положение электродов			
	1	2	3	1	2	3	1	2	3	
НБК	76.85	73.66	70.07	78.17	77.05	65.51	77.30	75.17	67.92	0.39
Дерево решений	88.91	78.86	69.41	90.17	78.47	68.72	88.83	79.87	68.66	0.26
Случайный лес	95.77	79.60	70.15	96.00	79.26	68.30	95.91	80.61	69.03	6.22
МОВ	88.31	69.46	57.62	91.00	77.56	59.21	88.27	71.47	56.47	0.34
Метод k -ближайших соседей	96.00	76.37	71.12	96.21	76.63	69.34	96.15	77.51	69.88	0.74
Градиентный бустинг	90.40	80.53	71.73	91.49	80.05	69.43	90.35	81.51	70.01	0.62
Ансамбль (НБК, дерево решений)	94.59	79.56	68.03	94.81	78.82	68.16	94.74	80.62	67.52	0.64
Ансамбль (НБК, градиентный бустинг)	94.82	80.88	71.21	95.11	80.24	69.31	94.9	81.92	69.75	1.06
Ансамбль (градиентный бустинг, дерево решений)	90.17	80.30	68.12	91.13	79.49	68.07	90.11	81.21	67.36	0.93

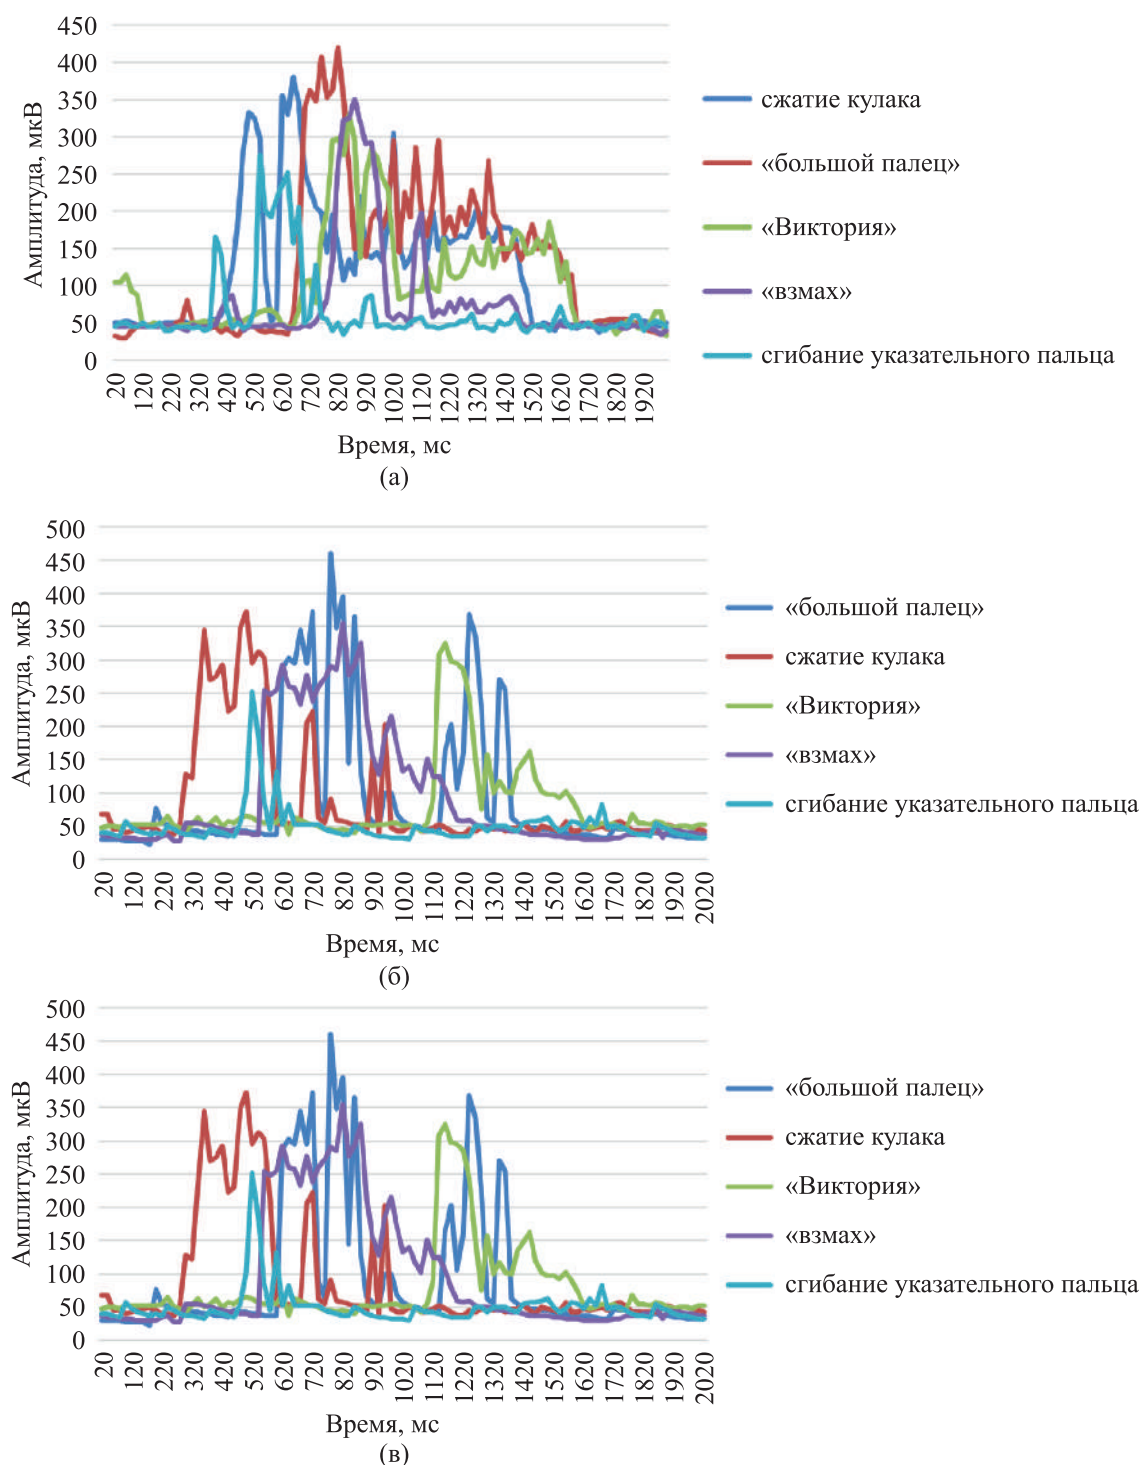


Рис. 8. Графики значений амплитуды ЭМГ сигналов при нахождении электродов в положении: 1 (а), 2 (б), 3 (в)

При проведении *эксперимента 1* один из дифференциальных электродов располагался на внутренней стороне руки на месте пересечения глубокого сгибателя пальцев и длинного сгибателя большого пальца, второй электрод находился над поверхностным сгибателем пальцев (рис. 7, а). Кривые амплитуды ЭМГ-сигнала для каждого рассматриваемого жеста в данном положении представлены на рис. 8, а.

Как видно из табл. 11, наибольшую точность распознавания жестов имеют методы k -ближайших соседей и «случайный лес».

Поскольку необходимым условием работы системы распознавания является способность функционировать в режиме реального времени, важно, чтобы задержка ответа системы была минимальна. Несмотря на высокую точность распознавания и малое количество ошибок метода k -ближайших соседей и метода «случайный лес», данные методы характеризуются значительным временем работы (0.74 и 6.22 мс соответственно, см. табл. 11). При этом на работу методов распознавания жестов, имеющих большее количество ошибок, таких как НБК, дерево решений и МОВ, требовалось меньше времени (0.26, 0.20 и 0.34 мс соответственно). Таким образом, наиболее эффективным является метод с минимальными количеством ошибок и временем работы.

Поскольку ЭМГ-электроды преимущественно располагались на мышцах, отвечающих за сжатие четырех пальцев руки, движение большого пальца зачастую не улавливалось классификаторами в достаточной степени. По этой причине большинство классификаторов распознавали жест «большой палец» ошибочно. В соответствии с матрицами ошибок (confusion matrix) НБК и дерева решений (рис. 9, а, б), НБК практически безошибочно распознает жест «большой палец», в то время как другие методы, в том числе дерево решений, достаточно точно классифицируют остальные четыре жеста. Кроме того, из табл. 11 видно, что эти два метода имеют наименьшее среднее время классификации (0.39 и 0.26 мс соответственно).

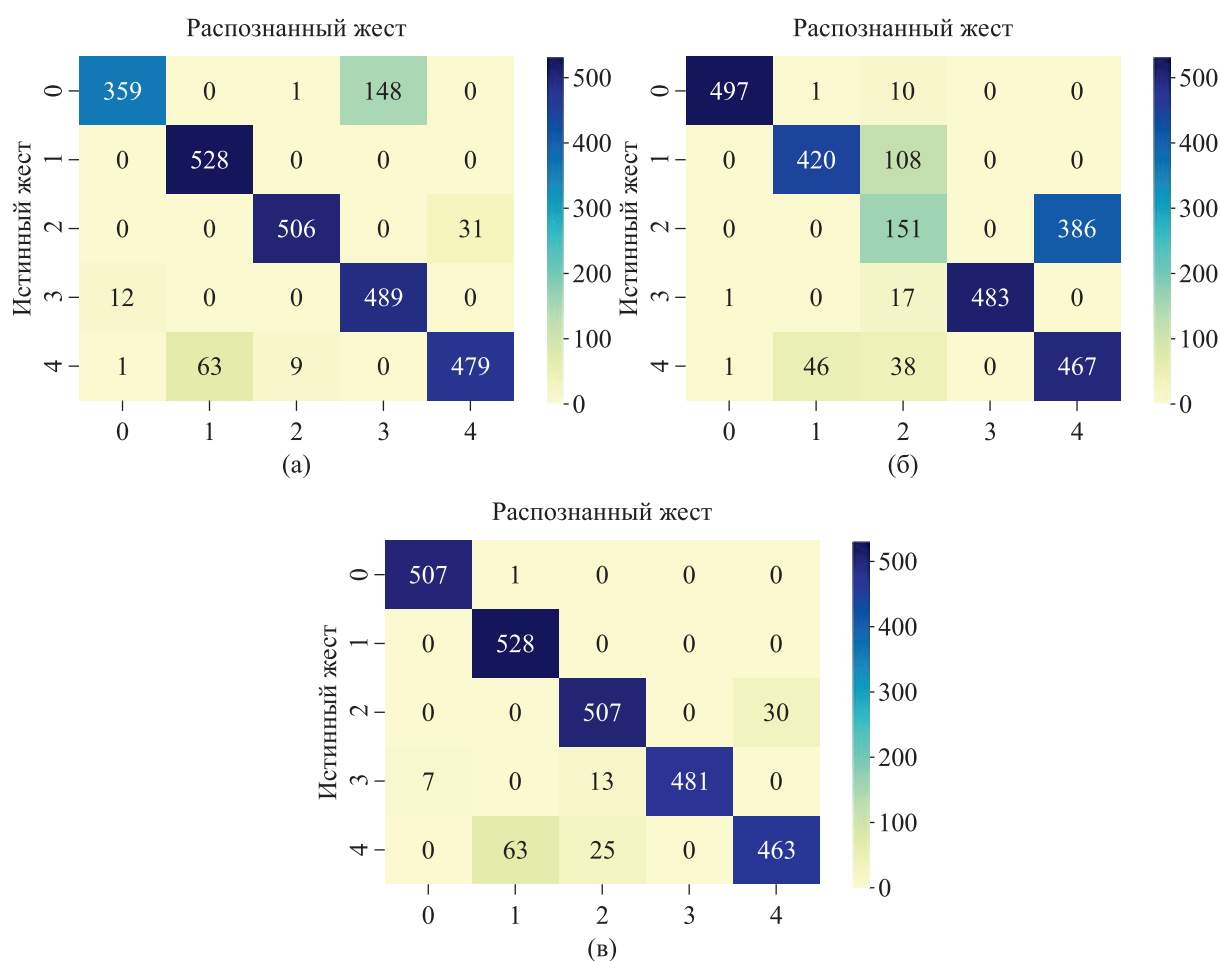


Рис. 9. Матрицы ошибок для эксперимента 1: а) дерево решений; б) НБК; в) ансамбль НБК и дерева решений. Обозначения жестов: 0 — кулак, 1 — сжатие указательного пальца, 2 — «Виктория», 3 — «большой палец», 4 — взмах

Ансамбль НБК и дерева решений позволяет существенно сократить количество ошибок, что подтверждается матрицей ошибок (рис. 9, в). Совместное использование данных методов позволяет компенсировать ошибки, возникающие при индивидуальной работе этих классификаторов.

При проведении *эксперимента 2* электроды на предплечье были расположены в соответствии с рис. 7, б. Оба дифференциальных электрода были закреплены в области длинного сгибателя большого пальца. Интенсивность сигнала для каждого из пяти жестов, полученная в данном эксперименте, представлена на рис. 8, б. Поскольку в эксперименте 2 электроды закреплялись на мышце, которая отвечает за работу большого пальца кисти руки, интенсивность сигнала при совершении жеста «большой палец» была более выраженной, чем в предыдущем эксперименте, и заметно превосходила интенсивность сигналов прочих жестов.

По результатам эксперимента (табл. 11) для положения электродов 2 одним из наиболее точных, но «медленных» классификаторов является метод «случайный лес» (точность 79.26 %, средняя скорость — 6.22 мс). Для всех классификаторов характерно ложное распознавание жеста «взмах» как «большой палец» и «Виктория» (рис. 10). Классификация жестов методом градиентного бустинга показала лучшую точность распознавания (80.05 %) при меньшем времени работы (0.62 мс) по сравнению со случайным лесом (79.26 %, 6.22 мс).

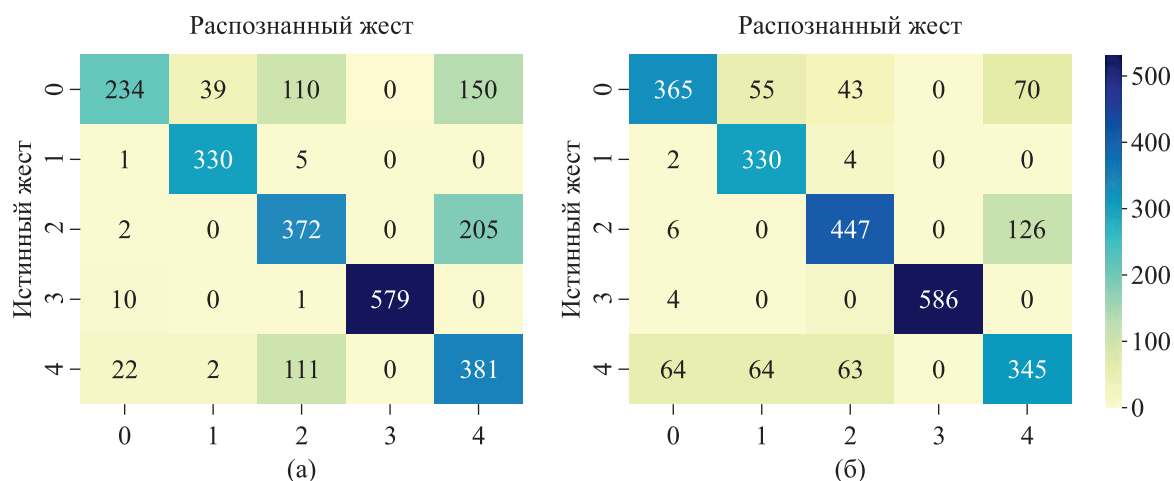


Рис. 10. Матрицы ошибок для эксперимента 2: а) НБК; б) градиентный бустинг. Обозначения жестов: 0 — кулак, 1 — сжатие указательного пальца, 2 — «Виктория», 3 — «большой палец», 4 — «взмах»

Ансамбль НБК и дерева решений, как и в эксперименте 1, превзошел по эффективности метод «случайный лес» с учетом соотношения точности классификации и времени работы. Данный ансамбль методов требует большее время для классификации по сравнению с градиентным бустингом (0.64 мс и 0.62 мс соответственно) и проигрывает градиентному бустингу в точности (78.82 % и 80.05 %, соответственно). Наибольшую точность классификации имеет ансамбль НБК и градиентного бустинга (80.24 %), однако по соотношению «точность/скорость» он является менее эффективным, чем градиентный бустинг.

Для проведения *эксперимента 3* электроды были расположены на внешней стороне предплечья. Один из дифференциальных электродов находился в зоне длинного разгибателя большого пальца и разгибателя указательного пальца (рис. 7, в). Другой электрод крепился над длинной мышцей, отводящей большой палец. На рис. 8, в представлены графики амплитуд ЭМГ-сигналов для каждого жеста при таком расположении электродов. ЭМГ-сигналы жестов «большой палец» имеют максимальную интенсивность сигнала по сравнению с другими жестами, что объясняется удобством крепления электродов на конкретных мышцах предплечья. Интенсивность сигнала жеста «Виктория» стала меньше по сравнению с предыдущими методами классификации движений, в то время как амплитуда сигнала жеста сгибания указательного пальца, наоборот, увеличилась. Такие результаты объясняются расположением электрода на мышце,

отвечающей за движение указательного пальца. Поэтому сжатие указательного пальца сопровождалось повышением амплитуды, а его выпрямление, характерное для жеста «Виктория», — уменьшением амплитуды. В табл. 11 представлены результаты распознавания жестов классификаторами, рассматриваемыми в эксперименте 3. Наиболее точными классификаторами среди рассматриваемых стали градиентный бустинг, метод k -ближайших соседей и метод «случайный лес». При этом большинство классификаторов имели однотипные ошибки. Матрицы ошибок градиентного бустинга и дерева решений представлены на рис. 11, из которого видно, что наибольшее число ошибок совершается при распознавании жестов «взмах», сжатия кулака и сгибания указательного пальца. Жест «большой палец» распознается преимущественно верно.

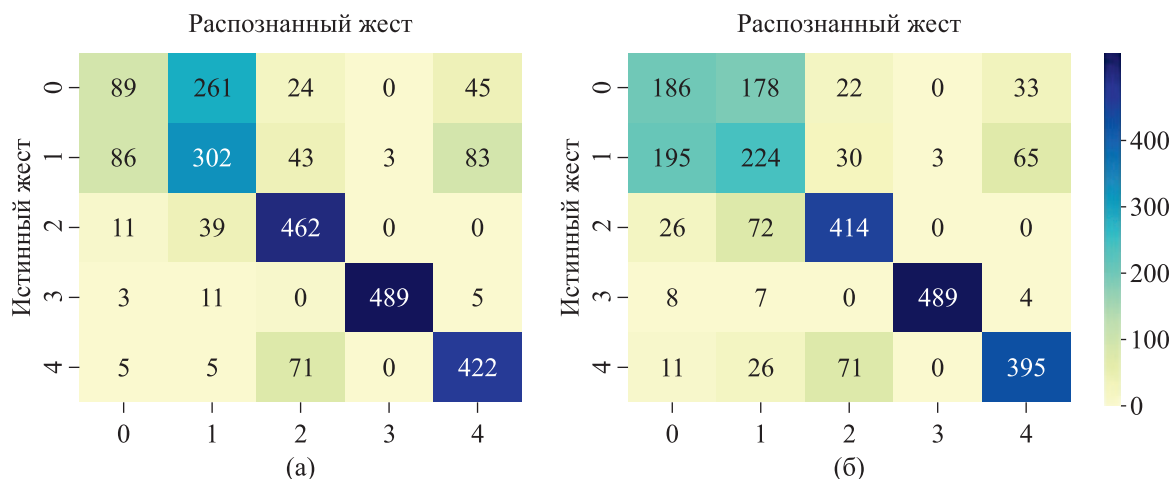


Рис. 11. Матрицы ошибок для эксперимента 3: а) градиентный бустинг; б) дерево решений. Обозначения жестов: 0 — кулак, 1 — сжатие указательного пальца, 2 — «Виктория», 3 — «большой палец», 4 — «взмах»

Наибольшую точность распознавания среди всех ансамблей имеет комбинация градиентного бустинга и НБК (69.31 %), при этом существенного уменьшения времени классификации достигнуть не удалось. Наиболее эффективным классификатором является градиентный бустинг, точность которого составила 69.43 %, за ним следует метод дерева решений с точностью 68.72 %, но с меньшим временем работы по сравнению с градиентным бустингом.

6. Обсуждение результатов

Эксперименты для трех различных положений электродов на предплечье не показали однозначно наиболее эффективный классификатор. Для анализа эффективности методов распознавания жестов были рассчитаны средние значения точности, сходимости и времени работы классификаторов (табл. 12).

Среди методов, обладающих сравнительно высокой точностью классификации, минимальное время распознавания жестов показал метод дерева решений (0.26 с, см. табл. 12). Наиболее точным является ансамбль методов НБК и градиентного бустинга, средняя точность которого для трех положений электродов составила 81.55 %. Остальные ансамбли методов НБК и градиентного бустинга, а также градиентного бустинга и дерева решений имеют большее значение времени работы по сравнению с базовыми классификаторами (1.06 с и 0.93 с соответственно). Это объясняется увеличением сложности при сочетании методов. С учетом соотношения параметров точности и времени работы наиболее эффективными классификаторами можно считать метод градиентного бустинга (80.32 %, 0.62 с), ансамбль методов («дерево решений» и НБК) (80.60 %, 0.64 с), метод k -ближайших соседей (80.73 %, 0.74 с) и дерево решений (79.12 %, 0.26 с).

Таблица 12. Усредненные результаты работы классификаторов

Классификатор	Доля правильных ответов, %	Точность, %	Полнота, %	Среднее время работы, мс
НБК	73.53	73.58	73.46	0.39
Дерево решений	79.06	79.12	79.12	0.26
Случайный лес	81.84	81.19	81.85	6.22
МОВ	71.80	75.92	72.07	0.34
Метод k -ближайших соседей	81.16	80.73	81.18	0.74
Градиентный бустинг	80.89	80.32	80.62	0.62
Ансамбль (НБК, дерево решений)	80.73	80.60	80.96	0.64
Ансамбль (НБК, градиентный бустинг)	82.30	81.55	82.19	1.06
Ансамбль (градиентный бустинг, дерево решений)	79.53	79.56	79.56	0.93

Точность распознавания жестов в первом эксперименте выше, чем во втором и третьем. Таким образом, схема крепления электродов на мышцах предплечья в эксперименте 1 является наилучшей из рассмотренных для регистрации ЭМГ-сигнала.

При использовании иных признаков жестов или же другого их количества результаты методов машинного обучения могут изменяться. Увеличение размерности векторов признаков может дать методам машинного обучения новую полезную информацию о жесте. Тем не менее бывают ситуации, когда признак не приносит дополнительные данные в алгоритмы распознавания, и его добавление в вектор признаков не несет существенного улучшения результатов, а иногда даже приводит к уменьшению точности распознавания. Таким образом, следует осуществлять выбор признаков и их количества, учитывая специфику используемого метода машинного обучения и возможность извлечения новой полезной информации из признаков.

Интерес представляет апробация нейронных сетей в задаче распознавания жестов, с помощью которых можно получить большую точность классификации жестов. Тем не менее скорость обучения нейронной сети существенно ниже, чем у методов машинного обучения, рассмотренных в данной работе, и данный подход значительно сложнее реализовать на микроконтроллере для работы в режиме реального времени.

7. Заключение

В данной работе представлен анализ методов распознавания жестов на основе машинного обучения: НБК, дерева решений, случайного леса, градиентного бустинга, МОВ, метода k -ближайших соседей и ансамблей методов (НБК и дерево решений, НБК и градиентный бустинг, градиентный бустинг и дерево решений). Для оценки эффективности работы классификаторов использовались точность распознавания, сходимость, полнота и время работы классификатора. Данные параметры были определены для трех случаев расположения электродов на предплечье. Проведенный анализ позволил определить положение электродов, при котором методы машинного обучения достигают наибольшего значения точности распознавания. По результатам трех проведенных экспериментов, положение, когда один из дифференциальных электродов располагается на месте пересечения глубокого сгибателя пальцев и длинного сгибателя большого пальца, второй над поверхностным сгибателем пальцев, является наиболее оптимальным с точки зрения точности распознавания жестов. Наибольшую эффективность имеют методы градиентного бустинга, k -ближайших соседей, «дерево решений» и ансамбль дерева решений и НБК.

Проведенный анализ эффективности методов машинного обучения в задаче распознавания жестов позволяет в дальнейшем рационализировать выбор того или иного метода машинного обучения в зависимости от задач, поставленных перед исследователем, будь то создание эле-

мента управления системы грузового захвата, повторяющего движение пальцев руки оператора, манипулятора, закрепленного на подвижной платформе для работы в агрессивных средах или в условиях чрезвычайных ситуаций, или тренажера для восстановления утерянных двигательных функций пациентов, переживших инсульт и другие заболевания, характеризующиеся частичной утратой двигательной активности.

Данная работа дает информацию об отклике сигналов мышц и реакции на них методов машинного обучения в зависимости от выполняемого пользователем жеста и расположения электродов на той или иной мышце, что также позволит исследователям более эффективно организовать получение ЭМГ-сигнала от биообъекта и его обработку.

Список литературы (References)

- Bolstad W. M., Curran J. M.* Introduction to Bayesian statistics. — John Wiley & Sons, 2016.
- Byun S. W., Lee S. P.* Implementation of Hand Gesture Recognition Device Applicable to Smart Watch Based on Flexible Epidermal Tactile Sensor Array // *Micromachines*. — 2019. — Vol. 10, No. 10. — P. 692. — DOI: 10.3390/mi10100692
- Cho Y., Lee A., Park J., Ko B., Kim N.* Enhancement of gesture recognition for contactless interface using a personalized classifier in the operating room // *Computer methods and programs in biomedicine*. — 2018. — Vol. 161. — P. 39–44. — DOI: 10.1016/j.cmpb.2018.04.003
- Demir N.* Ensemble Methods: Elegant Techniques to Produce Improved Machine Learning Results [Electronic resource]: <https://www.toptal.com/machine-learning/ensemble-methods-machine-learning> (дата обращения: 24.05.2020).
- Geng Y., Zhang X., Zhang Y. T., Li G.* A novel channel selection method for multiple motion classification using high-density electromyography // *Biomedical engineering online*. — 2014. — Vol. 13, No. 1. — P. 102. — DOI: 10.1186/1475-925X-13-102
- Hu Y., Wong Y., Wei W., Du Y., Kankanhalli M., Geng W.* A novel attention-based hybrid CNN-RNN architecture for sEMG-based gesture recognition // *PloS one*. — 2018. — Vol. 13, No. 10. — P. e0206049. — DOI: 10.1371/journal.pone.0206049
- Ke A., Huang J., Chen L., Gao Z., He J.* An Ultra-Sensitive Modular Hybrid EMG–FMG Sensor with Floating Electrodes // *Sensors*. — 2020. — Vol. 20 (17). — P. 4775. — DOI: 10.3390/s20174775
- Lee A., Cho Y., Jin S., Kim N.* Enhancement of surgical hand gesture recognition using a capsule network for a contactless interface in the operating room // *Computer Methods and Programs in Biomedicine*. — 2020. — Vol. 190. — P. 105385. — DOI: 10.1016/j.cmpb.2020.105385
- Lian K. Y., Chiu C. C., Hong Y. J., Sung W. T.* Wearable armband for real time hand gesture recognition // 2017 IEEE International Conference on Systems, Man, and Cybernetics (SMC). — IEEE, 2017. — P. 2992–2995.
- Lyu M., Lambelet C., Woolley D., Zhang X., Chen W., Ding X., Wenderoth N.* Training wrist extensor function and detecting unwanted movement strategies in an EMG-controlled visuomotor task // 2017 International Conference on Rehabilitation Robotics (ICORR). — IEEE, 2017. — P. 1549–1555.
- Mehra V.* Hand Gesture Recognition using Support Vector Machine and Bag of Visual Words model. — 2018. — DOI: 10.13140/RG.2.2.30175.97446
- Mirjalili S., Faris H., Aljarah I.* Evolutionary Machine Learning Techniques. — Springer, 2019.
- Molnar C.* Interpretable Machine Learning [Electronic resource]: <https://christophm.github.io/interpretable-ml-book/logistic.html> (дата обращения: 30.05.2020).
- Mor B., Garhwal S., Kumar A.* A Systematic Review of Hidden Markov Models and Their Applications // *Archives of computational methods in engineering*. — 2020. — DOI: 10.1007/s11831-020-09422-4

- Nagashree R. N., Michahial S., Aishwarya G. N., Azeez B. H., Jayalakshmi M. R., Rani R. K.* Hand gesture recognition using support vector machine // *International Journal of Engineering and Science*. — 2005. — Vol. 4, No. 6. — P. 42–46.
- Navlani A.* Support Vector Machines with Scikit-learn [Electronic resource]: <https://www.datacamp.com/community/tutorials/svm-classification-scikit-learn-python> 2019 (дата обращения: 10.04.2020).
- Nguyen T. N., Vo D. H., Huynh H. H., Meunier J.* Geometry-based static hand gesture recognition using support vector machine // *2014 13th International Conference on Control Automation Robotics & Vision (ICARCV)*. — 2014. — P. 769–774. — DOI: 10.1109/ICARCV.2014.7064401
- Purushothaman G., Ray K. K.* EMG based man-machine interaction — A pattern recognition research platform // *Robotics and Autonomous Systems*. — 2014. — Vol. 62, No. 6. — P. 864–870. — DOI: 10.1016/j.robot.2014.01.008
- Ryser F., Bützer T., Held J. P., Lambercy O., Gassert R.* Fully embedded myoelectric control for a wearable robotic hand orthosis // *2017 International Conference on Rehabilitation Robotics (ICORR)*. — IEEE, 2017. — P. 615–621. — DOI: 10.1109/ICORR.2017.8009316
- Sahin U., Sahin F.* Pattern recognition with surface EMG signal based wavelet transformation // *2012 IEEE intern. conf. on systems, man, and cybernetics (SMC)*. — IEEE, 2012. — P. 295–300. — DOI: 10.1109/ICSMC.2012.6377717
- Samadani A.* Emg channel selection for improved hand gesture classification // *40th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. — IEEE, 2018. — P. 4297–4300. — DOI: 10.1109/EMBC.2018.8513395
- Smith C., Koning M.* *Decision Trees and Random Forests: A Visual Introduction for Beginners*. — Independently published, 2017.
- Song W., Han Q., Lin Z., Yan N., Luo D., Liao Y., Chen Y.* Design of a flexible wearable smart sEMG recorder integrated gradient boosting decision tree based hand gesture recognition // *IEEE Transactions on Biomedical Circuits and Systems*. — 2019. — Vol. 13, No. 6. — P. 1563–1574.
- Tam S., Boukadoum M., Campeau-Lecours A., Gosselin B.* A Fully Embedded Adaptive Real-Time Hand Gesture Classifier Leveraging HD-sEMG and Deep Learning // *IEEE Transactions on Biomedical Circuits and Systems*. — 2019. — Vol. 14, No. 2. — P. 232–243. — DOI: 10.1109/TBCAS.2019.2955641
- Teachasrisaksakul K., Wu L., Yang G. Z., Lo B.* Hand gesture recognition with inertial sensors // *2018 40th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. — 2018. — P. 3517–3520. — DOI: 10.1109/EMBC.2018.8513098
- Zhang Y., Chen Y., Yu H., Yang X., Lu W., Liu H.* Wearing-independent hand gesture recognition method based on EMG armband // *Personal and Ubiquitous Computing*. — 2018. — Vol. 22, No. 3. — P. 511–524. — DOI: 10.1007/s00779-018-1152-3
- Zhang Z., Yang K., Qian J., Zhang L.* Real-time surface EMG pattern recognition for hand gestures based on an artificial neural network // *Sensors*. — 2019. — Vol. 19, No. 14. — P. 3170. — DOI: 10.3390/s19143170